

# De palabras de acción a señales de control

Isabela Duque-Henao, Valentina Lopera-Urbe

Facultad de Ciencias Exactas y Aplicadas, Institución Universitaria ITM

Medellín, Colombia

isabeladuque1117416@correo.itm.edu.co

valentinalopera1113844@correo.itm.edu.co

**Resumen** — En este estudio se exploraron señales de electroencefalografía (EEG) registradas durante tres paradigmas relacionados con la cognición motora (*Action Words*, *Motor Imagery* y *Motor Observation*) con el objetivo de distinguir patrones cerebrales asociados a movimientos de miembros superiores (ARM) e inferiores (LEG). Se adquirieron y procesaron 11 337 muestras EEG utilizando un sistema de ocho canales, y se evaluaron distintos métodos de extracción de características y clasificación. Aunque los modelos presentaron un rendimiento moderado debido a la complejidad inherente del EEG y la variabilidad entre sujetos, los resultados ofrecen una base inicial para comprender cómo el lenguaje, la imaginación y la observación de acciones modulan la actividad sensorimotora, y aportan lineamientos para futuros desarrollos en interfaces cerebro-computador basadas en estas dinámicas.

**Palabras clave**— *neurociencia, BCI, palabras de acción, imaginación motora, observación motora, Machine Learning, EEG, SVM, LDA, KNN, CSP, PSD, BP.*

## I. INTRODUCCIÓN

Las interfaces cerebro-computadora (BCI) permiten comunicarnos o controlar dispositivos usando únicamente la actividad cerebral, sin necesidad de movimientos musculares. Los paradigmas clásicos, como la Imaginación Motora (MI) y la Observación Motora (MO), han sido ampliamente utilizados porque generan patrones distinguibles en EEG, especialmente en las bandas mu y beta.

Sin embargo, estos enfoques dependen de instrucciones motoras explícitas. Para superar esta limitación, investigaciones recientes han mostrado que las *Action Words* —palabras que describen acciones como *patear* o *agarrar*— activan áreas motoras específicas durante su procesamiento semántico. Esto sugiere que el lenguaje puede generar señales cerebrales diferenciables según el tipo de acción, ofreciendo un nuevo camino para el diseño de BCI más naturales e intuitivos.

Explorar este vínculo entre lenguaje y actividad motora es el objetivo central de este proyecto: evaluar si las *Action Words* pueden funcionar como estímulos capaces de producir patrones neuronales clasificables y útiles como señales de control para un Language-Related BCI.

## II. LITERATURA Y ESTADO DEL ARTE

### Paradigmas tradicionales en BCI: Imaginación Motora (MI)

Las BCI no invasivas basadas en imaginación motora (Motor Imagery, MI) han sido uno de los enfoques más estudiados durante

las últimas dos décadas [1], [2]. En este paradigma, el usuario imagina un movimiento sin ejecutarlo físicamente, generando modulaciones características en bandas como mu (aprox. 8–13 Hz) y beta (aprox. 13–30 Hz), detectables mediante EEG. Los trabajos clásicos han demostrado que estas variaciones permiten discriminar entre diferentes movimientos imaginados, como mano derecha, mano izquierda o pie [1].

En los últimos años, el rendimiento de las BCI basadas en MI ha mejorado gracias al uso de técnicas de extracción de características como Common Spatial Patterns (CSP) y Power Spectral Density (PSD), además de clasificadores como SVM, LDA, y redes neuronales profundas. Por ejemplo, revisiones recientes documentan que MI-BCI, con métodos modernos, sigue siendo un enfoque robusto y ampliamente investigado [3], [4]. A pesar de estos avances, el paradigma presenta limitaciones importantes: requiere entrenamiento prolongado, depende fuertemente de la concentración del usuario y suele mostrar gran variabilidad entre sujetos [3], [5].

### Paradigmas emergentes basados en lenguaje y procesamiento semántico

Frente a las limitaciones de MI, una línea emergente de investigación busca explotar funciones cognitivas más naturales, como el lenguaje, para generar señales de control en BCI. Investigaciones recientes han explorado la posibilidad de decodificar señales EEG durante “habla imaginada” (imagined speech) o tareas de procesamiento semántico, lo que sugiere una vía alterna al paradigma motor [6].

En particular, el dataset público EEG-based BCI Dataset of Semantic Concepts for Imagination and Perception Tasks presenta datos EEG (124 canales) para tareas de percepción e imaginación de contenido semántico, mostrando que existen iniciativas reales para investigar BCI basadas en semántica/lenguaje [7].

Estudios recientes de decodificación de “imagined speech” han utilizado técnicas de aprendizaje profundo (redes CNN + LSTM, etc.) partiendo de EEG, con resultados prometedores aunque todavía modestos en muchos casos [8]. Por ejemplo, un estudio reporta que mediante un modelo híbrido 3D-CNN + RNN se logró clasificar palabras imaginadas a partir de EEG, evidenciando la factibilidad del enfoque bajo condiciones controladas [8].

Sin embargo (y aquí está el reto), estos estudios también indican que las señales provenientes del procesamiento lingüístico o semántico presentan alta variabilidad inter-sujeto, baja relación señal-ruido, y dificultades para generalizar resultados, por lo que la decodificación aún es un desafío [6], [9].

#### Comparación entre MI y BCI basadas en lenguaje

Aspecto	Paradigma MI-BCI	Paradigmas basados en Lenguaje
Madurez del campo	Muy avanzado, con décadas de investigación y métodos estables [1], [3]	Emergente, pocos estudios y datasets limitados [6], [7]
Precisión / desempeño	Alta, entre 80–90 % en escenarios de clasificación con métodos modernos [4], [5]	De moderada a baja: <50–90 % dependiendo del método y sujeto [8], [9]
Robustez / generalización	Aumentando con métodos profundos y aprendizaje representacional [4], [5]	Muy limitada; alta variabilidad entre sujetos, paradigmas no estandarizados [6], [9]
Complejidad de comandos	Limitada al repertorio motor	Potencialmente enorme: vocabulario, semántica, acciones lingüísticas
Carga cognitiva	Moderada; requiere concentración sostenida	Menor; el lenguaje es natural y automático
Dificultades técnicas	Artefactos EEG, no-estacionariedad, variabilidad inter-sujeto [3]	Lo anterior + baja SNR semántica + falta de datasets [6], [7], [9]

**Tabla 1.** Comparación entre MI y BCI basadas en lenguaje

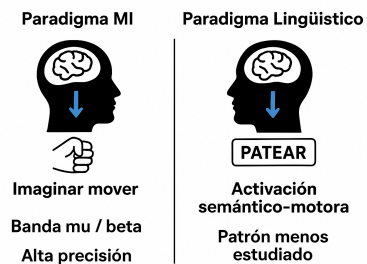
#### Coincidencias, contradicciones y vacíos en la literatura

Los estudios coinciden en que las señales EEG —tanto para MI como para lenguaje— son **ruidosas** y requieren preprocesamiento robusto (filtrado, remoción de artefactos, normalización). También existe acuerdo en la importancia de emplear métodos como CSP, análisis espectral y clasificadores supervisados para mejorar el rendimiento [3], [4].

Sin embargo, la literatura muestra contradicciones importantes: algunos trabajos reportan buenos niveles de discriminación utilizando palabras imaginadas [8], mientras que otros obtienen desempeños modestos o no generalizables [9]. Esto se debe en parte a la falta de protocolos estandarizados, diferencias en el número de sujetos y variabilidad cognitiva individual.

Finalmente, la revisión revela varios vacíos claros:

1. Escasez de estudios que comparen directamente MI con paradigmas basados en lenguaje dentro de un mismo protocolo experimental.
2. Muy poca evidencia sobre el uso de *action words* para distinguir tren superior vs. tren inferior, lo cual constituye el núcleo de tu proyecto.
3. Necesidad de explorar paradigmas híbridos (MI + lenguaje) para aumentar la robustez.
4. Ausencia de trabajos que integren semántica con deep learning multimodal, que podría mejorar rendimiento.



**Figura 1.** Ilustración paradigmas

### III. PREGUNTA DE INVESTIGACIÓN

*¿Pueden las action words generar patrones neuronales suficientemente diferenciables en EEG —asociados al tren superior e inferior del cuerpo— para ser utilizados como señales de control en una BCI, y cómo se compara su desempeño con un paradigma tradicional de imaginación motora?*

## Justificación

Esta pregunta se fundamenta en los vacíos detectados en la literatura reciente:

- Falta de estudios sistemáticos que comparen action words frente a paradigmas MI en condiciones experimentales equivalentes.
- Escasa evidencia empírica sobre la capacidad de las palabras de acción para activar patrones neuronales relacionados con el tren superior/inferior.
- Alta variabilidad y falta de estandarización en experimentos de procesamiento semántico e imagined speech.
- Necesidad de paradigmas alternativos más intuitivos y menos demandantes cognitivamente que MI.

Abordar estos vacíos permite explorar un nuevo paradigma lingüístico-motor en BCI y evaluar su viabilidad práctica.

## IV. OBJETIVOS

### Objetivo general

Analizar el potencial de las action words como estímulos capaces de generar patrones neuronales diferenciables asociados al tren superior e inferior —registrados mediante EEG— para su uso como señales de control en una interfaz cerebro-computadora, comparando su rendimiento con un paradigma tradicional de imaginación motora durante un periodo experimental definido.

### Objetivos específicos

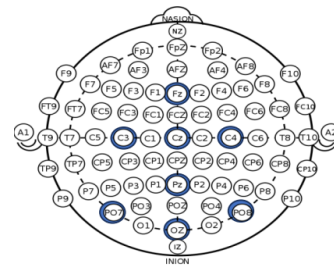
1. Caracterizar los patrones neuronales generados durante el procesamiento de action words en tareas de lectura, imaginación semántica y visualización motora, utilizando análisis espectral (PSD) y espacial (CSP) sobre señales EEG.
2. Comparar el rendimiento de clasificación entre un paradigma basado en action words y un paradigma clásico de imaginación motora, empleando modelos supervisados como SVM y validación cruzada.
3. Evaluar el aporte de los potenciales relacionados con eventos (ERP) asociados al procesamiento semántico en la discriminación entre clases correspondientes al tren superior e inferior.
4. Determinar la precisión, sensibilidad y especificidad del sistema BCI basado en lenguaje, y analizar su variabilidad inter-sujeto frente al paradigma MI durante

el periodo experimental del semestre.

## V. DATOS Y ANÁLISIS PRELIMINAR

### Descripción del dataset

El presente estudio utilizó un conjunto de datos de EEG registrado mediante un sistema *Unicorn Hybrid Black®*, compuesto por ocho electrodos activos dispuestos según el sistema internacional 10–20. La configuración incluyó los siguientes puntos de registro: **Fz (1)**, **C3 (2)**, **Cz (3)**, **C4 (4)**, **Pz (5)**, **PO7 (6)**, **PO8 (7)** y **Oz (8)**, los cuales permiten captar actividad cortical asociada al procesamiento motor y visomotor, incluyendo áreas premotoras, motoras primarias, corteza parietal posterior y región occipital. [10]



**Figura 2.** Posición de electrodos

El objetivo del experimento fue analizar la respuesta cerebral asociada a diferentes paradigmas de interacción cerebro-computador basados en lenguaje y acción. Los participantes realizaron tareas pertenecientes a tres paradigmas experimentales:

1. **Action Words (AW):** presentación de palabras que describen acciones (“correr”, “saltar”, etc.).
2. **Motor Imagery (MI):** imaginación kinestésica de movimientos de extremidades.
3. **Motor Observation (MO):** observación de videos con acciones motoras.

En los tres paradigmas, la variable objetivo consistió en clasificar el tipo de miembro involucrado en la acción:

- **ARM:** acciones o imaginación/observación relacionadas con miembros superiores.
- **LEG:** acciones o imaginación/observación relacionadas con miembros inferiores.

Así, la variable objetivo **y** es categórica (ARM vs. LEG), mientras que las variables explicativas **X** corresponden a los valores de

voltaje de los ocho canales EEG más variables asociadas a metadatos del trial (tiempo, tarea, sujeto, género).

El dataset final estuvo compuesto por **11 337 muestras** (filas), luego del proceso de adquisición, segmentación y consolidación de los archivos XDF provenientes de los tres paradigmas experimentales.

Los datos fueron recolectados en un laboratorio de la Institución Universitaria de Envigado (IUE), bajo consentimiento informado aprobado por el comité institucional. En total participaron **24 individuos** (12 mujeres y 12 hombres), distribuidos equitativamente en cada tipo de tarea (AW, MI, MO), tal como se ilustra en la Figura correspondiente. [11]

### Protocolo de adquisición

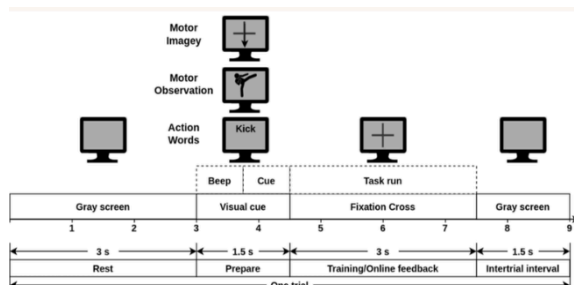
El protocolo experimental integró sincronización de estímulos y adquisición EEG mediante *Python (PsychoPy)* y el sistema de streaming *Lab Streaming Layer (LSL)*. La interacción entre estímulos, marcadores y señal EEG se resume así:

- PsychoPy presentó los estímulos correspondientes a cada paradigma y envió los marcadores del evento.
- El Unicorn Hybrid Black envió las señales EEG crudas vía LSL.
- Un Lab Recorder consolidó en tiempo real EEG + marcadores en archivos XDF.

Cada trial siguió una estructura temporal compuesta por:

1. Periodo de descanso (3 s)
2. Periodo de preparación (1.5 s, con señal acústica)
3. Ejecución de la tarea (3 s)
4. Intervalo intertrial (1.5 s)

como se muestra en la siguiente ilustración:



**Figura 3.** Protocolo del experimento

Este diseño permitió aislar la actividad cortical asociada al proceso motor y prever posibles contaminaciones por anticipación o post-acción.

### Estructura del dataset

La base de datos consolidada contiene las siguientes variables:

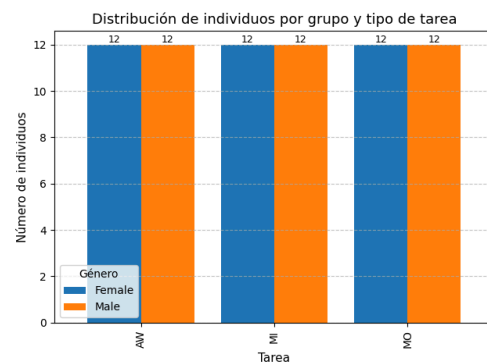
- **Ch\_1 – Ch\_8:** voltaje EEG por canal ( $\mu V$ ).
- **Time\_s:** tiempo relativo del registro en segundos.
- **Target:** etiqueta del miembro involucrado (ARM/LEG).
- **Task:** tipo de paradigma (AW, MI, MO).
- **Subject:** identificador único del participante.
- **Gender:** género autorreportado del sujeto.

Las señales provienen de regiones corticales relevantes para la modulación sensorimotora:

- **C3, C4, Cz** → actividad motora y somatosensorial (seleccionados finalmente)
- **Fz** → control atencional y preparación motora
- **Pz, PO7, PO8, Oz** → integración visomotora y procesamiento visual

### Análisis exploratorio de datos (EDA)

La muestra estuvo balanceada por género y por condición, con 12 hombres y 12 mujeres distribuidos equitativamente en los tres paradigmas (AW, MI, MO). Esto reduce posibles sesgos de género en la respuesta cortical. La siguiente imagen muestra dicha estadística:



**Figura 4.** Conteo individuos que participaron en el experimento

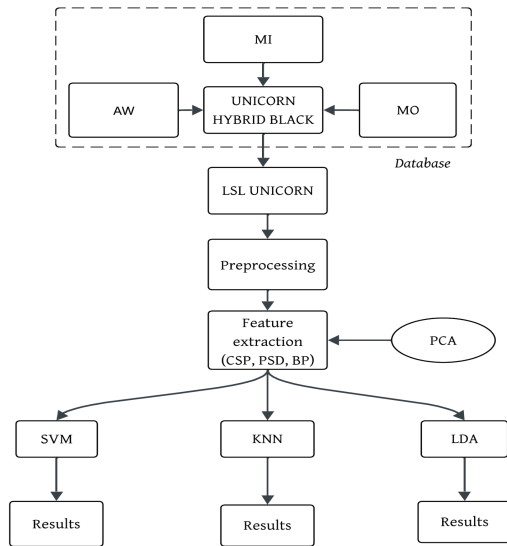
Las etiquetas ARM y LEG estuvieron distribuidas de manera equilibrada dentro de cada paradigma, reduciendo riesgos de desbalance que afecten el entrenamiento del modelo.

## VI. METODOLOGÍA

### Limpieza, procesamiento y preparación del dataset

Las señales EEG fueron adquiridas mediante el sistema Unicorn Hybrid Black® y transmitidas en tiempo real utilizando Lab Streaming Layer (LSL). Posteriormente, los archivos XDF fueron

procesados de forma offline siguiendo el flujo ilustrado en la Figura X.



**Figura 5.** Flujo de los datos

El preprocesamiento incluyó:

- Filtrado pasa banda para aislar componentes entre los rangos típicamente asociados a la actividad cortical oscilatoria relevante (1–40 Hz).
- Revisión y eliminación de artefactos evidentes debidos a parpadeo, tensión muscular o discontinuidades en la señal.
- Segmentación por trial, alineando cada ventana temporal con los marcadores de estímulo correspondientes a los paradigmas AW, MI y MO.
- Estandarización de amplitudes, con el fin de homogenizar las señales entre sujetos y reducir la variabilidad interindividual.

El resultado de esta etapa fue un conjunto de 11 337 muestras EEG depuradas, listas para la extracción de características.

### **División del dataset en entrenamiento y prueba**

Para construir y evaluar los modelos de clasificación se utilizó una división **80/20** del dataset.

Esta proporción se seleccionó debido a que la cantidad total de muestras era suficientemente amplia para mantener:

- un conjunto de entrenamiento robusto, que permitiera aprender patrones establemente, y
- Un conjunto de prueba representativo, capaz de evaluar el rendimiento general del sistema sin sesgos.

La división se realizó de forma estratificada, asegurando que ambas clases objetivo (ARM y LEG) estuvieran equilibradas en cada partición.

### **Extracción y selección de características**

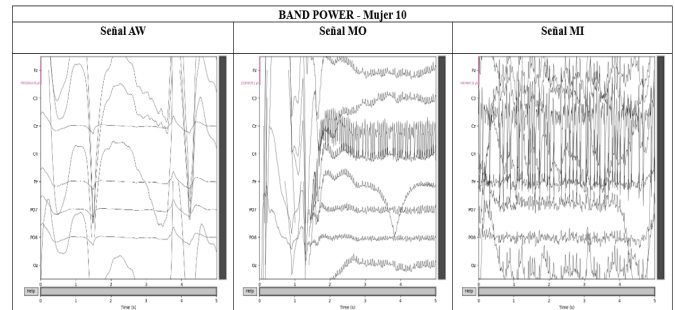
A partir de los ocho canales EEG se implementaron tres estrategias de extracción de características, ampliamente utilizadas en sistemas BCI:

a) **Band Power (BP)** se calcularon potencias en las bandas:

Banda	Frecuencias	Asociada a
<b>Delta</b>	1–4 Hz	sueño profundo, procesos automáticos
<b>Theta</b>	4–8 Hz	memoria, navegación, sueño ligero
<b>Alpha</b>	8–13 Hz	relajación, inhibición cortical
<b>Beta</b>	13–30 Hz	actividad motora, atención

**Tabla 2.** Selección de bandas característica BP

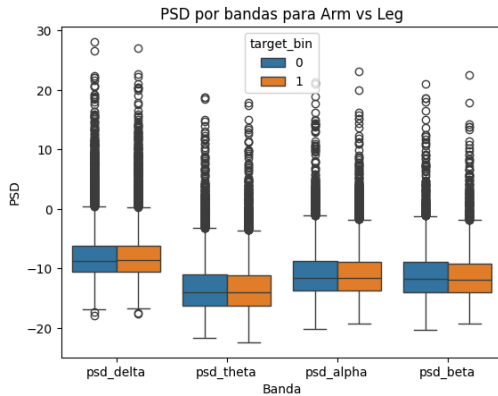
Estas características capturan oscilaciones vinculadas a atención, activación sensoriomotora y procesamiento cognitivo/motor.



**Figura 6.** Resultados Band Power Female 10

La inspección visual de las señales EEG para un sujeto representativo muestra variaciones sustanciales entre paradigmas, con una mayor complejidad y amplitud en la actividad durante MI respecto a AW y MO. Sin embargo, a pesar de estas diferencias generales, la morfología de las señales no presenta patrones distintivos que permitan diferenciar de manera consistente entre movimientos de miembros superiores e inferiores. Esto indica que, si bien los paradigmas generan dinámicas corticales diferentes, estas no se traducen en diferencias suficientemente sistemáticas entre ARM y LEG dentro de cada paradigma, limitando la capacidad de los modelos para clasificar la acción motora basada únicamente en la actividad EEG registrada.

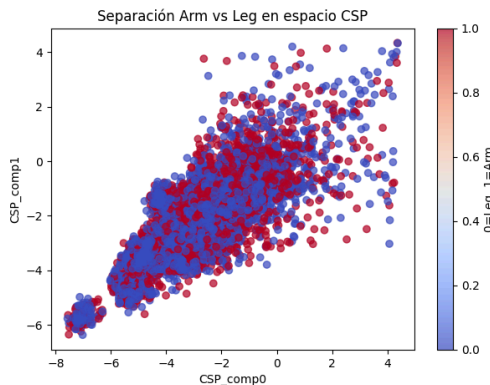
**b) Power Spectral Density (PSD) :** Se estimó la densidad espectral mediante métodos de análisis en frecuencia. Debido a la alta dimensionalidad resultante, se aplicó reducción de dimensionalidad mediante PCA, conservando los componentes que explicaban mayor varianza y reduciendo ruido y redundancia.



**Figura 7. Resultados PSD**

Los resultados de PSD por bandas muestran distribuciones prácticamente equivalentes entre las clases ARM y LEG en las bandas delta, theta, alpha y beta. Las medianas y dispersiones se superponen casi por completo, lo que evidencia que la potencia espectral asociada a estas bandas no presenta diferencias significativas entre los dos tipos de movimiento. Esta ausencia de contrastes espectrales relevantes explica por qué los clasificadores basados en PSD (incluso con reducción dimensional mediante PCA que se visualizará mas adelante) no logran capturar patrones diferenciadores y arrojan desempeños cercanos al azar.

**c) Common Spatial Patterns (CSP):** Se empleó CSP para maximizar la separabilidad espacial entre los dos targets (ARM vs. LEG), técnica especialmente adecuada para tareas motoras imaginadas, observadas o lingüísticas relacionadas con acción.



**Figura 8. Resultados CSP**

El análisis en el espacio de características CSP evidencia que los patrones espaciales derivados de la señal EEG no permiten una clara separación entre las clases ARM y LEG. Los puntos correspondientes a ambos grupos se solapan ampliamente en las dos primeras componentes, lo que sugiere que la actividad cortical

registrada por los ocho canales no presenta diferencias suficientemente robustas o consistentes entre movimientos de miembros superiores e inferiores. Este solapamiento coincide con el rendimiento cercano al azar de los clasificadores, indicando que la variabilidad y baja discriminabilidad de los patrones espaciales limitan la capacidad de separación en este dominio.

### Matriz de características

Las características BP, los componentes PCA derivados del PSD y las proyecciones espaciales CSP fueron combinadas para formar una nueva matriz de características, que constituyó el dataset final de entrada a los clasificadores.

Esta matriz integró información temporal (capturada indirectamente en BP y PSD), espectral (distribución de frecuencia), espacial (patrones de activación cortical derivados de CSP)

lo que permitió representar de manera más completa la actividad cerebral asociada a cada paradigma experimental.

## VII. RESULTADOS

Los 3 modelos de Machine Learning utilizados según revisión del estado del arte fueron Máquinas de soporte Vectorial (SVM), análisis discriminante lineal (LDA) y k-Vecinos Más Cercanos (KNN) siendo este último el que nos permitió alcanzar los mejores resultados.[12]

El modelo **K-Nearest Neighbors (KNN)** fue entrenado y evaluado para la clasificación de señales EEG asociadas a *Action Words* correspondientes al tren superior (*Arm*) e inferior (*Leg*). Se utilizó validación cruzada estratificada (5-fold) junto con una búsqueda exhaustiva de hiperparámetros.

### Optimización del modelo KNN

El proceso de búsqueda (GridSearchCV) evaluó un total de 180 combinaciones de parámetros, explorando variaciones en:

- **Número de vecinos:**  $1 \leq k \leq 30$
- **Ponderación:** *uniform* y *distance*
- **Métricas de distancia:** *euclidean*, *manhattan*, *minkowski*

Los mejores hiperparámetros encontrados fueron:

**metric:** manhattan    **n\_neighbors:** 30    **weights:** distance

La siguiente gráfica muestra el comportamiento del accuracy del modelo KNN al variar el número de vecinos ( $k$ ). Este análisis permitió identificar la tendencia general del modelo y confirmar por qué GridSearchCV seleccionó  $k = 30$  como uno de los mejores valores dentro del rango evaluado.

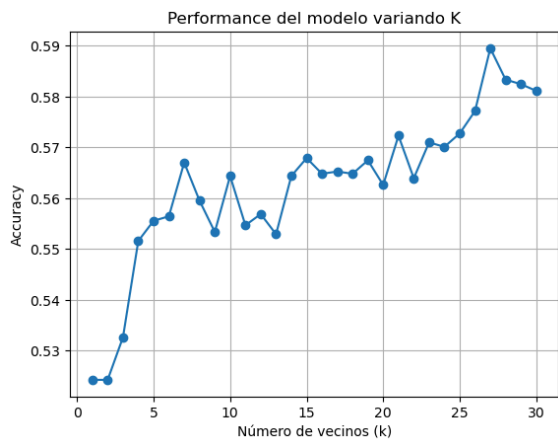


Figura 9 .Accuracy del modelo KNN al variar el número de vecinos ( $k$ )

El mejor score de validación cruzada obtenido fue = **0.6628**

Este valor sugiere un rendimiento moderado, consistente con lo reportado en la literatura para paradigmas basados en lenguaje y procesamiento semántico.

#### Evaluación sobre datos de prueba

La Tabla 3 presenta las métricas obtenidas en el conjunto de prueba con KNN.

Clase	Precisión	Recall	F1-score	Soporte
Arm	0.65	0.74	0.69	1136
Leg	0.69	0.60	0.64	1132
Accuracy total	<b>0.67</b>	—	—	2268
Macro Avg	0.67	0.67	0.67	—
Weighted Avg	0.67	0.67	0.67	—

Tabla 3. Reporte de clasificación del modelo KNN

El accuracy final de **0.67** coincide estrechamente con la precisión estimada por validación cruzada (0.6628), lo que sugiere un modelo estable y sin sobreajuste significativo.

#### Matriz de confusión

La siguiente figura resume la capacidad del modelo para discriminar entre clases.

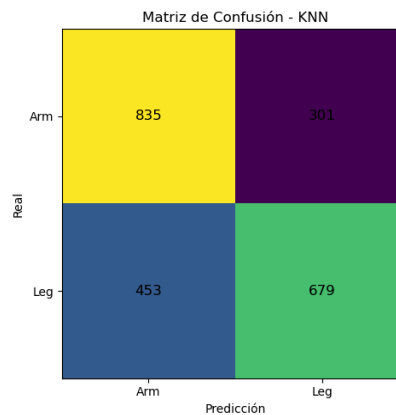


Figura . Distribución datos KNN en matriz de confusión

Los resultados obtenidos con el modelo **KNN** muestran un desempeño moderado, con un accuracy total de 0.67 (Tabla 3), valor que coincide de forma estrecha con la estimación obtenida mediante validación cruzada (0.6628). Esta similitud entre el rendimiento en validación cruzada y el conjunto de prueba sugiere que el modelo presenta buena estabilidad y no evidencia sobreajuste significativo, lo cual es consistente con el comportamiento esperado de KNN bajo configuraciones de hiperparámetros adecuadamente optimizadas.

En términos de discriminación entre clases, el modelo presenta un comportamiento desigual. La clase “Arm” alcanza un recall de 0.74, mientras que la clase “Leg” obtiene un recall de 0.60. La matriz de confusión (Figura X) confirma esta asimetría: la clase Leg concentra un número mayor de falsos negativos (453), lo que indica que el modelo tiende a confundir estas muestras con la clase Arm. Este patrón sugiere que las características asociadas a una de las categorías presentan mayor consistencia interna, mientras que las de la otra clase muestran mayor variabilidad, dificultando su separación.

Los resultados obtenidos con los clasificadores **SVM** y **LDA**, evaluados sobre los tres paradigmas experimentales (AW, MI y MO), muestran un comportamiento consistente y muy cercano al nivel de azar (~50 %). Tanto la precisión, el recall y el F1-score se mantienen en el intervalo 0.48–0.56 en todos los casos, y las matrices de confusión revelan una distribución simétrica de aciertos y errores entre las clases ARM y LEG.

Aunque los valores de LDA son ligeramente superiores en MI y MO, la mejora es mínima y no representa una discriminabilidad real entre clases. En general, ambos modelos evidencian que los patrones EEG obtenidos con esta configuración experimental **no**

presentan separabilidad clara entre movimientos de miembros superiores e inferiores.

Paradigma	Clasificador	Accuracy	Precision (clase 0)	Precision (clase 1)	Recall (clase 0)	Recall (clase 1)	F1 (clase 0)	F1 (clase 1)
AW	SVM	0.51	0.51	0.51	0.59	0.43	0.54	0.47
MI		0.50	0.50	0.50	0.47	0.53	0.48	0.51
MO		0.51	0.51	0.51	0.54	0.47	0.52	0.49
AW	LDA	0.51	0.51	0.51	0.46	0.56	0.48	0.53
MI		0.52	0.53	0.52	0.44	0.61	0.48	0.56
MO		0.51	0.51	0.52	0.49	0.54	0.50	0.53

Tabla 4. Comparación SVM - LDA

Analizando la tabla anterior es posible evidenciar que ambos modelos rondan 50–52 % de exactitud, equivalente al azar. LDA supera ligeramente a SVM en MI y MO, pero la diferencia no es significativa. En algunos casos, una clase (ARM o LEG) tiene mejor recall que la otra, pero no de manera consistente entre paradigmas, lo que indica falta de patrones estables en el EEG. La ausencia de ganancias reales entre clasificadores confirma que el problema radica en la señal, no en el algoritmo.[13]

Los resultados obtenidos se encuentran alineados con lo reportado en investigaciones recientes sobre paradigmas basados en lenguaje y contenido semántico en EEG. A diferencia de los sistemas BCI tradicionales basados en Imaginación Motora (MI), cuya precisión puede situarse entre el 80–90 % en configuraciones bien optimizadas, los paradigmas basados en lenguaje muestran, en general, un rendimiento más modesto y una mayor variabilidad entre sujetos. Esto coincide con lo observado en este trabajo: aunque se logra una discriminación por encima del azar y con métricas estables, el desempeño aún se sitúa por debajo de los estándares de MI-BCI.

Los estudios de decodificación semántica, habla imaginada o tareas lingüísticas reportan precisiones muy variables, que pueden ir desde valores cercanos al azar hasta resultados intermedios (50–70 %) según el modelo y la calidad del preprocesamiento [8], [9]. Esto concuerda con el resultado obtenido (0.67), ubicándolo dentro de un rango típico para paradigmas basados en lenguaje y lejos del desempeño robusto de paradigmas motores consolidados. Por tanto, el rendimiento del modelo no contradice la literatura: más bien confirma el reto inherente a trabajar con contenido semántico en EEG debido a su baja relación señal/ruido y alta variabilidad cognitiva.

Asimismo, la literatura señala que las señales asociadas a procesos lingüísticos pueden presentar menos estabilidad y mayor dispersión inter-sujeto, lo cual podría explicar la diferencia observada entre clases. Estudios previos sobre action words también han reportado diferencias en la activación cortical entre

conceptos relacionados con acciones del tren superior e inferior, lo que podría contribuir a la asimetría observada en los resultados.

## VII. TRABAJO FUTURO

Para continuar mejorando el desempeño en la clasificación de señales EEG, es necesario ampliar el conjunto de datos utilizado, incorporando más sujetos, sesiones y condiciones de registro que permitan entrenar modelos más generalizables. Igualmente, sería valioso explorar técnicas de preprocesamiento más robustas (como filtros adaptativos, corrección de artefactos y normalización avanzada) que reduzcan el ruido característico de este tipo de señales.

Adicionalmente, se propone evaluar otros métodos de extracción de características, incluyendo enfoques basados en wavelets, descomposición espectral o aprendizaje no supervisado. También resulta prometedor comparar algoritmos tradicionales con modelos más recientes, como redes recurrentes, transformers especializados en series temporales o CNN híbridas. Finalmente, integrar interpretabilidad del modelo podría ayudar a comprender mejor qué patrones del EEG están asociados a cada acción, facilitando aplicaciones futuras en interfaces cerebro-computador.

Este experimento también fue contratado con una encuesta que se le hizo a cada participante, en donde se le preguntaba si tenía un alto consumo de redes sociales, si juega videojuegos, si conduce algún vehículo o actividades relacionadas, que pueden ser contrastadas con las señales para entender mejor la actividad neuronal y ver si la persona es realmente apta para realizar este tipo de proyectos.

## VII. CONCLUSIÓN

El proyecto permitió desarrollar un flujo completo para la clasificación de señales EEG, desde la adquisición y construcción de la base de datos hasta la extracción de características y la evaluación de distintos modelos de aprendizaje automático. Los resultados obtenidos evidenciaron que el desempeño del clasificador depende de manera significativa de la calidad del preprocesamiento y de la selección adecuada de hiperparámetros.

Aunque las métricas alcanzadas fueron moderadas, el trabajo demostró la viabilidad de distinguir categorías de Action Words mediante modelos supervisados y destacó la importancia de técnicas como la validación cruzada y la búsqueda exhaustiva de parámetros para obtener configuraciones óptimas. En conjunto, el proyecto sienta bases metodológicas sólidas y abre camino a investigaciones futuras que podrían mejorar la precisión y trasladar estos avances a aplicaciones reales de interfaces cerebro-computador.

## REFERENCIAS

- [1] G. Pfurtscheller and F. H. Lopes da Silva, “Event-related EEG/MEG synchronization and desynchronization,” *Clin. Neurophysiol.*, 1999.
- [2] J. R. Wolpaw et al., “Brain-computer interfaces for

communication and control,” *Clin. Neurophysiol.*, 2002.

[3] C. Padfield et al., “EEG-based Brain–Computer Interfaces using Motor-Imagery,” *Sensors*, 2019.

[4] J. T. Tsivilis et al., “EEG-Inception,” *arXiv*, 2021.

[5] A. Craik et al., “Deep learning for EEG classification,” *J. Neural Eng.*, 2019.

[6] E. Rupp et al., “Imagined Speech Classification Methods,” *Frontiers in Human Neuroscience*, 2022.

[7] BCI Semantic Concepts Dataset, *Scientific Data*, 2023.

[8] K. Lu et al., “Hybrid CNN–RNN for Imagined Speech EEG,” *MDPI Life*, 2024.

[9] S. Sereshkeh et al., “Challenges in imagined speech decoding,” *Frontiers in Neuroscience*, 2022.

[10] Tutorial for running AW-BCI experiment, BCI\_AW\_TUTORIAL, UNICORN SB, 2019

[11] Documento de Consentimiento Libre, Previo e Informado (CLPI), Línea de Investigación en Automatización Industrial – Grupo de Investigación en Sistemas e Informática. Institución Universitaria de Envigado, 2024.

[12] F. Lotte, L. Bougrain, A. Cichocki, M. Clerc, M. Congedo, A. Rakotomamonjy, y F. Yger, “A review of classification algorithms for EEG-based brain–computer interfaces: a 10 year update,” *Journal of Neural Engineering*, vol. 15, no. 3, Art. ID 031005, Abr. 2018.

[13] Benjamin Blankertz, Steven Lemm, Matthias Treder, Stefan Haufe, Klaus-Robert Müller, Single-trial analysis and classification of ERP components — A tutorial, *NeuroImage*, Volume 56, Issue 2, 2011, Pages 814-825, ISSN 1053-8119.